

INFORME FINAL: ANÁLISIS DE COMPORTAMIENTO Y SOPORTE DE USUARIOS DE STREAMING

Enlaces del Proyecto:

- **Repositorio GitHub:** https://github.com/A-D-Vargas/PI_Mineria_Datos_1.git
- **Aplicación de Visualización:** [Enlace a Streamlit Cloud]

1. Contexto y Objetivo

El mercado de las plataformas de entretenimiento digital exige una constante optimización de sus servicios para garantizar la permanencia de los suscriptores. Este proyecto surge de la necesidad de comprender la interacción de los clientes con el servicio, evaluando cómo sus características demográficas y el tipo de plan contratado influyen en sus hábitos de consumo y en la generación de incidentes técnicos.

El **objetivo general** de la investigación consiste en analizar el comportamiento de los usuarios, sus preferencias de contenido y los problemas de soporte técnico para descubrir qué factores impulsan el consumo y detectar fallas críticas en el servicio, aportando información estratégica que facilite la toma de decisiones orientadas a la retención de clientes.

2. Dataset y Calidad Inicial

El conjunto de datos original contenía información detallada sobre los usuarios de la plataforma, distribuidos en variables cualitativas (país, género preferido, tipo de suscripción) y cuantitativas (edad, minutos de visualización mensuales y tickets de soporte técnico generados).

En su estado inicial, la base de datos presentaba, por ejemplo, registros completamente duplicados y la presencia de valores nulos o faltantes en columnas estratégicas para el análisis. Asimismo, existían inconsistencias menores en los formatos de las cadenas de texto y en la asignación de tipos de variables.

3. Decisiones de Limpieza y Preparación

Para asegurar la integridad de los análisis posteriores, se ejecutó un proceso sistemático de preparación de datos que constó de las siguientes decisiones metodológicas:

- **Depuración:** se eliminaron de forma absoluta todos los registros duplicados, reduciendo el ruido estadístico.
- **Tratamiento de Nulos:** se aplicaron técnicas de imputación controlada para resolver la ausencia de datos en variables críticas.
- **Estandarización:** se transformaron los nombres de todas las variables a un formato uniforme y se corrigieron las diferencias de tipos de datos, convirtiendo variables de texto a categorías formales.
- **Consistencia de Rangos:** se validó que las variables numéricas (como la edad y los minutos mensuales) se encontraran dentro de límites lógicos para el negocio, consolidando un dataset final y limpio de 8,018 registros perfectamente estructurados.

4. Hallazgos del Análisis Exploratorio

La exploración estadística (univariada, bivariada y multivariada) arrojó certezas fundamentales sobre el comportamiento del negocio:

- **Impacto de los Planes:** el nivel de suscripción es la variable que más influye en el tiempo de uso. Los usuarios con plan Premium registran una mediana de consumo de ~1,081 minutos mensuales, duplicando el rendimiento de los usuarios con plan Básico (~557 minutos).

- **Preferencia de Contenidos:** el consumo Premium no solo es mayor en volumen, sino que se concentra en géneros de larga duración como Drama y Documentales, mientras que los planes Básicos consumen principalmente Acción y Crimen.
- **Independencia de la Edad:** se demostró que la edad de los usuarios posee una correlación de 0.00 con el tiempo de visualización. Los gustos cinematográficos y la frecuencia de uso están distribuidos de manera uniforme; la edad no segmenta el consumo.
- **Fricción en Soporte Técnico:** el volumen de uso mensual no genera de forma lineal un incremento en las fallas. Sin embargo, el análisis geográfico detectó una anomalía crítica: los clientes Premium ubicados en Chile y Perú concentran el promedio más alto de tickets de soporte técnico de toda la plataforma.

5. Análisis de Componentes Principales (PCA)

Con el propósito de evaluar una posible reducción de dimensionalidad, se aplicó un escalamiento estándar (StandardScaler) sobre las variables cuantitativas (edad, minutos mensuales y tickets de soporte).

Al ejecutar el modelo de PCA, los resultados determinaron que cada una de las tres componentes principales explicaba de manera equitativa aproximadamente el ~33% de la varianza total (acumulando un 66.9% al utilizar dos componentes). Este fenómeno matemático corrobora la nula correlación lineal entre las variables originales. Al no existir redundancia de información, se determinó que la reducción de dimensiones no era una técnica viable para este dataset. La decisión técnica óptima fue conservar las tres variables originales escaladas para no distorsionar ni perder integridad en los datos.

6. Conclusiones y Limitaciones

Conclusiones

El estudio permite concluir que las estrategias de recomendación y distribución del catálogo de contenidos deben diseñarse en función del plan contratado por el usuario y desvincularse de segmentaciones tradicionales por rangos de edad, ya que las preferencias demostraron ser transversales.

En el plano operativo, se enciende una alerta comercial de alta prioridad: la empresa debe realizar una auditoría urgente sobre la infraestructura y el soporte del servicio Premium en Chile y Perú. Resolver las fallas técnicas específicas en estas regiones es la acción directa más importante para mitigar el riesgo de cancelación de cuentas en el segmento de clientes de mayor valor económico.

Limitaciones

- El alcance de las conclusiones se encuentra estrictamente condicionado por la información disponible en el dataset original, el cual cuenta con un número reducido de variables numéricas, limitando el aprovechamiento de modelos analíticos avanzados o de reducción dimensional.
- Los resultados se encuentran acotados por la ausencia de un registro histórico continuo (mes a mes), lo que impide identificar patrones de estacionalidad o evaluar tendencias de comportamiento del usuario a largo plazo.